TODO

- Undergraduate Research Opportunities -

Dragoş Alin Rotaru Mentor: Ruxandra F. Olimid

Universitatea din București ROMANIA r.dragos0@gmail.com

Abstract. TODO - abstract

Cuprins

T(ODO		1
	Dra	goş Alin Rotaru Mentor: Ruxandra F. Olimid	
1	Intro	oducere	3
	1.1	Istoric	3
	1.2	Motivatie	3
	1.3	Structura	3
	1.4	Securitatea Teoretica a Informatiei	3
2	$\operatorname{Sch}\epsilon$	eme de partajare	4
	2.1	Istoric	4
	2.2	Schema unanimă	5
	2.3	Schema Shamir	5
	2.4	Schema Ito, Saito şi Nishizeki	6
3	Siste	eme de stocare de lunga durata	7
	3.1	Criptare VS scheme de partajare	8
4	Siste	eme de stocare de lungă durată bazate pe scheme de partajare	9
	4.1	PASIS	9
	4.2	GridSharing	10
	4.3	POTSHARDS	13
5		emul de stocare Alouneh et al	14
6	Rez	ultate obținute	16
	6.1	Vulnerabilități evidențiate	17
	6.2	Implementare şi rezultate practice	19
	6.3	Publicarea rezultatelor	26

1 Introducere

1.1 Istoric

Termenul de criptografie este definit in dictionarul Oxford ca fiind "arta de a scrie si a rezolva coduri". Criptografia moderna s-a desprins de cea clasica in jurul anilor '80, motivand implementarea rigurozitatii matematice pentru definirea constructiilor criptografice. Asta pentru ca in anii anteriori, experienta a dovedit nesiguranta metodelor de criptare, criptanaliza lor fiind uneori triviala (cifrul lui Cezar, Vigenere [1], [2]) sau uneori atinsa cu ceva mai mult efort precum Enigma si alte metode din cel de-al doilea razboi mondial. ??

Criptografia moderna se gaseste pretutindeni in viata de zi cu zi de la ATM-uri, cartele telefonice la semnaturi digitale, protocoale de autentificare, licitatii electronice sau bani digitali, luand amploare o data cu aparitia sistemelor cu cheie publica. O definitie potrivita ar fi "studiul stiintific al tehnicililor pentru a securiza informatia digitala, tranzactiile si calculul distribuit.". [3]

1.2 Motivatie

TODO nu are legătură: faptul ca sunt scheme cuantice nu are impact asupra structurii de acces; e ok sa menționezi, dar atunci faci asta în secțiunea anterioară, când poți să adaugi și alte modalități de definire: scheme bazate pe latici, scheme bazate pe perechi biliniare, scheme cuantice, etc. Dezavantajul schemelor generale de partajare este dimensiunea componentelor, exponentiala in functie de numarul de participanti. [4] De asemenea, s-au dezvoltat scheme pentru modele de calcul neconventional, cum ar fi cel cuantic. [5]

1.3 Structura

TODO

1.4 Securitatea Teoretica a Informatiei

In cazul unor criptosisteme acestea nu pot fi compromise chiar daca adversarul dispune de o putere computationala nelimitata. Cateva exemple de criptosisteme care garanteaza securitatea teoretica-informationala sunt: schemele de partajare, unele protocoale multi-party computation, preluarea intr-un mod sigur(securizat?) informatii de la baze de date. Securitatea teoretica vine insa cu un cost: efortul computational depus este mult mai mare decat in cazul schemelor care nu garanteaza securitatea teoretica (se bazeaza pe dificultatea computationala unor probleme cunoscute). [6]

2 Scheme de partajare

O schemă de partajare constă în distribuirea unei informații secrete S la mai mulți participanți $P = \{P_1, \ldots, P_n\}$ astfel încât oricare mulțime de participanți predefinită ca făcând parte dintr-o structură de acces pe care o vom denumi A să poată reconstitui secretul S. Formal, o schemă de partajare este reprezentată de o pereche de algoritmi (Gen, Rec):

- Gen(S, m) este un algoritm care primește la intrare un secret S și un număr întreg m și întoarce un set de componente s_1, s_2, \ldots, s_m .
- $Rec(s_{i1}, s_{i2}, \ldots, s_{iq})$ este un algoritm care primește ca parametri de intrare o mulțime de componente și întoarce S dacă mulțimea $\{P_{i1}, P_{i2}, \ldots, P_{iq}\} \in \mathcal{A}$.

Majoritatea schemelor constau în mai multe etape precum:

- Initializare. Presupune inițializarea variabilelor de mediu necesare.
- Generare. O entitate autorizată (numită dealer) \mathcal{D} folosește algoritmul Genepentru a genera componentele.
- Distribuție. Componentele sunt trimise participanților cu ajutorul unui mijloc de comunicare sigur, fără ca acestea sa fie vizibile unui atacator.
- Reconstrucție. Dându-se o mulțime de componente, se folosește algoritmul Rec pentru a recupera secretul S.

Schemele de partajare se clasifică in funcție de cantitatea de informație secretă pe care o pot obține persoanele care nu fac parte din \mathcal{A} [7]:

- Sisteme perfecte de partajare: componentele nu oferă nici o informatie teoretică despre $\mathcal S$ indiferent de resursele computaționale.
- Sisteme statistic sigure: o fracțiune de informație este dezvaluită despre \mathcal{S} independent de puterea computională a adversarului.
- Sisteme computațional-sigure de partajare: se bazează pe faptul ca reconstituirea lui \mathcal{S} se reduce la o problema dificilă (spre exemplu problema Diffie-Hellman [8]) în lipsa unor informații oferite doar grupului de acces \mathcal{A} .

În continuare vom prezenta cateva sisteme perfecte de partajare utilizate în cadrul unor arhitecturi pentru stocarea fisierelor pe o durata indelungată.

2.1 Istoric

Primele scheme de partajare au fost dezvoltate independent de Shamir şi Blakley in 1979 [9, 10].

Denumite și scheme majoritare (k,n), acestea rezolvau cazul în care oricare grup de participanți cu un număr mai mare sau egal decât k (mărimea pragului) poate reconstitui secretul $\mathcal S$ din componentele primite de la dealer. Dacă schema este

perfect sigură atunci oricare grup cu un număr de participanți mai mic decat k nu obține vreo informație despre S.

Schemele majoritare (spre exemplu schema Shamir) sunt insuficiente pentru a permite partajarea pentru anumite structuri de acces. Considerăm cazul în care vrem sa partajam un secret între 4 participanți: P_1, P_2, P_3, P_4 astfel încât $\{P_1, P_2\}$ și $\{P_3, P_4\}$ să fie singurele mulțimi autorizate pentru reconstrucția secretului S (i.e. $\mathcal{A} = \{\{P_1, P_2\}, \{P_3, P_4\}\}$). În mod evident, problema nu poate fi rezolvată cu o structură de acces de tip prag: anumite mulțimi de 2 participanți trebuie să poată reconstrui secretul $(\{P_1, P_2\}, \{P_3, P_4\})$, în timp ce altele nu $(\{P_1, P_3\}, \{P_1, P_4\}, \{P_2, P_3\}, \{P_2, P_4\})$

Astfel de scheme de partajare pentru structuri de acces generale au fost dezvoltate de Ito, Saito și Nishizeki, realizând o generalizare a schemei Shamir [11]. Benaloh și Leichter au demonstrat ca schemele de partajare de tip prag nu pot fi folosite pe structuri general monotone (familie de submulțimi ale lui \mathcal{P} cu proprietatea că dacă $A \in \mathcal{A}$ și $A \subset A'$, atunci $A' \in \mathcal{A}$) și obțin o construcție mai eficientă ca Ito et. al din punct de vedere al numărului de componente distribuite participanților [12].

2.2 Schema unanimă

Presupunând ca vrem să impărțim un secret S la n participanți astfel încât S sa poată fi recuperat doar daca toți cei n participanți își combină componentele pe care le dețin. Metoda este echivalentă cu o schemă (n, n) majoritară. Un exemplu este schema introdusă de Karin, Greene și Hellman (Fig.1) [13].

2.3 Schema Shamir

Schema Shamir oferă mai multă flexibilitate decât schema unanima prin faptul ca oricare k (sau mai multi) participanți din cei n pot recupera \mathcal{S} , însă mai puțin de k participanți nu obțin nicio informație despre \mathcal{S} . Schema Shamir este deci o schemă (k, n) majoritară.

Intuitiv, având k puncte in plan $(x_i, y_i), x_i \neq x_j \ i, j \in \{1, 2, ..., k\} \ \forall i \neq j$, existâ o curbă polinomială unică care trece prin ele. În schimb, pentru a defini o curbă polinomială de grad k care trece prin k-1 puncte date, există o infinitate de soluții. Evident, orice submulțime de valori s_i de mărime egală cu k este suficientă și necesară pentru a reconstrui polinomul f. Dupa interpolarea componentelor deținute de cel puțin k dintre participanți, secretul \mathcal{S} se determină ca fiind f(0) (Fig. 2) [10].

Pentru un atacator care deține chiar și k-1 valori s_i , acesta nu determină nimic despre \mathcal{S} , spațiul de soluții posibile fiind identic față de situația în care nu reușește sa obțină vreo componentă.

```
Iniţializare:

- Fie S \in Z_q unde q > 1 şi q prim;

- Fie n numărul de participanţi;

Generare: Dealerul \mathcal{D}:

- Alege n-1 valori aleatoare s_i \leftarrow^R Z_p, i \in \{1,2,\ldots,n-1\};

- s_n = S + \sum_{i=1}^{n-1} s_i \pmod{q};

Distribuţie: Dealerul \mathcal{D}:

- transmite în mod sigur participantului P_i componenta s_i, i \in \{1,2,\ldots,n\};

Reconstrucţie: Cei n participanţi:

- Calculează S = \sum_{i=1}^n s_i \pmod{q}.
```

Fig. 1: Schema unanimă [13]

2.4 Schema Ito, Saito şi Nishizeki

În continuare vom descrie modalitatea de distribuire a componentelor de la care au pornit Ito, Saito şi Nishizeki pentru ca schema sa aiba o structură de acces $\mathcal{A} \subseteq 2^P$ (submulțime a setului de participanți) monotonă (i.e. $\forall A \in \mathcal{A}, A \subseteq A' \Rightarrow A' \in \mathcal{A}$) [11]. Folosind construcția unei scheme majoritare (k, n) autorii au reușit să descrie elementele din \mathcal{A} folosind rezultatul unei reuniuni de mulțimi de componente cu un număr de elemente mai mare sau egal decat k (Fig. 3) [11]. Notația x : Pr, înseamnă că x are proprietatea x

Dezvantajul acestei structuri este numărul de componente necesar pentru o structură de acces oarecare \mathcal{A} . Un mod simplu de construire al funcției Assign este următorul: pentru fiecare mulțime minimală $A \in \mathcal{A}$ ($\forall B \in \mathcal{A}, B \neq A, B \not\subset A$) se folosește o schemă de partajare unanimă (|A|, |A|) a lui \mathcal{S} pentru participanții din A.

Exemplul 1. Fie structura de acces $A = \{\{P_1, P_2\}, \{P_1, P_3, P_4\}\}.$

- Generăm componentele s_1, s_2 a.î. $s_1 \oplus s_2 = \mathcal{S}$ cu ajutorul schemei unanime (2, 2),
- Generăm componentele s_3, s_4, s_5 a.î. $s_3 \oplus s_4 \oplus s_5 = \mathcal{S}$ cu ajutorul schemei unanime (3,3)

Participanții primesc in felul următor componentele:

Inițializare:

- $\begin{array}{lll} \mbox{ Fie } S \in Z_q \mbox{ unde } q > 1 \mbox{ și } q \mbox{ prim;} \\ \mbox{ Fie } n \mbox{ numărul de participanți a.i } q > n; \end{array}$
- Fie k numărul minim de componente puse in comun pentru a determina pe S;

Generare: Dealerul \mathcal{D} :

- Alege *n* valori distincte $x_i \leftarrow^R Z_q$, i = 1, 2, ..., n;
- Alege $a_i \leftarrow^R Z_q$, $i \in \{1, 2, \dots, k-1\}$, $a_{k-1} \neq 0$; Construiește polinomul $f(x) = a_{k-1}x^{k-1} + a_{k-2}x^{k-2} + \dots + a_1x + \mathcal{S}$;
- Calculează $s_i = f(x_i), i \in \{1, 2, \dots, n\};$

Distribuție: Dealerul \mathcal{D} :

- Transmite participantului P_i componenta $s_i, i \in \{1, ..., n-1\};$

Reconstrucție: Orice mulțime cu dimensiunea k (sau mai mare) de participanți distincți P_1, P_2, \ldots, P_k :

– Interpolează punctele s_i pentru a obține polinomul f:

$$f(x) = \sum_{i=1}^{k} s_i \prod_{1 < j < k, j \neq i} \frac{x - x_j}{x_i - x_j}$$
 (1)

- Află secretul reconstruit S = f(0).

Fig. 2: Schema Shamir [10]

- $-P_1:\{s_1,s_3\};$
- $-P_2:\{s_2\};$
- $-P_3:\{s_3\};$
- $-P_4:\{s_4\};$

Sisteme de stocare de lunga durata

In acesta sectiune vom arata cateva intrebuintari ale schemelor de partajare. Consideram cazul in care vrem sa stocham rapoarte medicale, imagini, documente clasificate pe un timp indelungat intr-un mediu electronic. Pe parcursul timpului, pot apare in schimb, diverse probleme precum dezastre naturale, defectiunea unor componente hardware, eroare umana, etc [14]. Un sistem de stocare necesar nevoilor noastre trebuie sa satisfaca cel putin urmatoarele 3 conditii:

Inițializare:

- Fie q un număr prim $q, q > 1, z \in \mathbb{N}$ nenul și $\mathcal{C} = GF(p^z)$;
- Fie $S \in \mathcal{C}$ secretul;
- Fie structura de acces A;
- Fie *n* numărul de participanți;

Generare: Dealerul \mathcal{D} :

- Alege n valori distincte $x_i \leftarrow^R Z_q$, i = 1, 2, ..., n;
- Alege $a_i \leftarrow^R C \setminus \{0\}, i \in \{1, 2, \dots, k-1\}, a_{k-1} \neq 0;$
- Construieşte polinomul $f(x) = a_{k-1}x^{k-1} + a_{k-2}x^{k-2} + + a_1x + S;$
- Atribuie $s_i = f(x_i) \ i \in \{1, 2, ..., n\}$; Fie Shares = $\{s_1, ..., s_n\}$;
- Alege $D_i \subseteq Shares \ 1 \le i \le n;$
- Alege funcția $Assign: P \to 2^Q$:

 - $Assign(P_i) = D_i \ 1 \le i \le n$ $\mathcal{A} = \left\{ Q \subseteq Shares : \left| \bigcup_{P_i \in Q} Assign(P_i) \right| \ge k \right\};$

Distribuție: Dealerul \mathcal{D} :

- Transmite participantului P_i componenta $Assign(P_i), i \in {1, 2, ..., n}$;

Reconstrucție: Participanții din structura de acces A:

- Procedeaza identic ca in schema Shamir.

Fig. 3: Schema Ito, Saito, si Nishizeki [11]

- Disponibilitatea: Informatia trebuie sa ramana accesibila tot timpul, in ciuda erorilor de tip hardware.
- Integritatea: Abilitatea sistemului de a raspunde cererilor intr-un mod care garanteaza corectitudinea lor.
- Confidentialitatea: O persoana care nu face parte din grupul de acces sa nu obtina permisiunea de a afla informatii de orice fel despre datele existente in sistem.

Criptare VS scheme de partajare

Una dintre solutiile existente pentru a construi acest sistem ar putea fi criptarea datelor folosind o cheie inainte de inserarea lor in spatiul de stocare. In momentul in care un user autorizat doreste sa efectueze o citire a unor date, intrebuinteaza cheia potrivita pentru a le decripta. In practica exista algoritmi de criptare eficienti precum AES insă aceaștia nu garantează confidențialitatea datelor în cazul în care avem de a face cu un adversar fara o limita computationala. Un dezavantaj al criptarii este adminstrarea cheilor, standardele de securitatea schimbanduse in fiecare an. De fiecare data cand cheile sunt inlocuite atunci este necesara recriptarea datelor de pe fiecare baza de date. Cu cat disponibilitatea este mai mare - numarul de noduri duplicate creste- recriptarea lor devine o operatie costisitoare.

Majoritatea tehnicilor de criptarea se bazeaza pe dificultatea factorizarii unui numar sau cea a calcularii logaritmului discret insa o data cu posibila dezvoltare a calculatoarelor cuantice aceste probleme nu vor mai fi atat de dificile [15].

4 Sisteme de stocare de lungă durată bazate pe scheme de partajare

O alternativă la soluția cu criptare care asigură atât confidențialitate cât și redundanța necesară este intrebuințarea sistemelor de stocare de lungă durată bazate pe scheme de partajare [14, 16, 17].

4.1 PASIS

PASIS este o soluție pentru un sistem descentralizat care oferă beneficii precum securitate, redundanță a datelor si auto-întreținere [16] Structurile descentralizate împart informația la mai multe noduri folosind scheme de redundanța precum "Redundant Array of Independent Disks" (RAID) pentru a asigura performanța, scalabilitatea sistemului dar și integritatea datelor [18]. RAID reprezintă o tehnologie ce combină 2 concepte ortogonale precum data striping (aranjarea datelor pe discuri multiple într-o manieră secvențială - Fig ??) și redundanță pentru o disponibilitate ridicată [19].

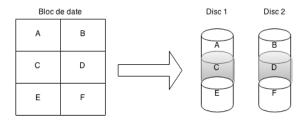


Fig. 4: Procesul de striping aplicat unui bloc de date

PASIS folosește schemele de partajare pentru a distribui informația nodurilor de stocare dintr-o rețea. Aceasta introduce agenți pe partea clientului pentru a scrie sau șterge date din noduri, dar și agenți pentru mentenanță. Componentele obtinute în urma partajării unui fisier sunt stocate in rețea cu ajutorul agenților (Fig. 5). Pe lângă conținutul brut al componentelor se adaugă metadate pentru a reține adresa nodului din rețea la care au fost stocate dar și noua denumire cu care este salvată in rețea.

Considerând o schemă de partajare majoritară (k,n) unde oricare din cei k participanți pot reconstitui fisierul, dar mai puțin de k nu obțin nicio informație dintr-un total de n componente.

Atunci când un participant inițiază o cerere pentru a citi un fisier, agentul PASIS aflat local procedează dupa cum urmează:

- Caută numele celor n componente care alcătuiesc fișierul într-un serviciu care listează toate datele.
- Inițiaza cereri de citire la cel puțin k din cele n noduri.
- În caz ca acesta nu primește cel puţin k răspunsuri se întoarce la pasul anterior încercând interogări la noduri diferite.
- Reconstituie fișierul obținut din cele k componente.

Operația de scriere este similară cu cea de citire, aceasta oprindu-se atunci când în cel puțin n-k+1 noduri s-au stocat cu succes componente. În articol se menționează și compromisul de spațiu-timp folosit de PASIS în funcție de alegerea schemei de partajare. Spre exemplu, cererile de citire pot fi făcute la acele k noduri pentru care răspunsurile recente au fost cele mai rapide. Autorii specifică soluții pentru auto mentenanța sistemului cu ajutorul resurselor umane prin monitorizarea periodică stării sistemului folosind log-uri sau ajustarea parametrilor din cadrul schemei de partajare.

4.2 GridSharing

In 2005, Subbiah şi Blough propun o nouă abordare pentru a construi un sistem de stocare securizat şi tolerant la erori numit GridSharing [17].

Schema Shamir nu oferă siguranță în ceea ce privește detectarea sau actualizarea unor componente incorecte introduse de un atacator. Metoda cea mai des folosită este determinarea validității componentelor prin utilizarea semnăturilor electronice. Aceasta este realizată prin scheme de verificare non-interactive precum cea a lui Feldman construită pe baza schemei Shamir [20] (Fig. 6)

Pentru verificarea componentei $s_i = f(i)$, participantul i probează ecuația:

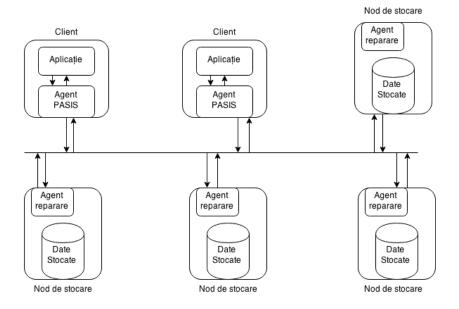


Fig. 5: Arhitectura PASIS cu 4 noduri și 2 clienți [16].

Inițializare: Folosind notațiile din Fig. 2, considerăm polinomul f generat în urma Schemei Shamir.

– Se alege un $g \in Z_q$ generator al lui $Z_q;$

Generare: Dealerul \mathcal{D} :

– Calculează angajamentele: $c_0 = g^S, c_j = g^{a_j}, j \in \{1, \dots, k\};$

Distribuție: Dealerul \mathcal{D} :

– Distribuie angajamentele $c_j, j \in \{0, \dots, k\}$ fiecărui participant $i \in \{1, \dots, n\}$;

Fig. 6: Schema Feldman [20]

$$g^{s_i} = c_0 c_1^i c_2^{i^2} \dots c_t^{i^t} = \prod_{j=0}^k c_j^{i^j} = \prod_{j=0}^k g^{a_j i^j} = g^{\sum_{j=0}^k a_j i^j} = g^{f(i)}$$
 (2)

Subbiah și Blough folosesc un sistem care înlocuiește schemele de verificare cu o schemă de partajare unanimă XOR (considerăm cazul q=2 în Fig. 1) pentru a păstra securitatea construcției. În cazul detectării componentelor incorecte, este adoptată o strategie de tipul replicate-and-voting. Componentele sunt replicate pe un număr mare de servere astfel încât determinarea validității va fi stabilită în funcție de numărul de servere care le conțin.

Se identifică 3 tipuri de defecțiuni care pot apărea pe serverele unde sunt stocate datele:

- Abandonări: un server este abandonat dacă nu mai raspunde vreunui mesaj din rețea şi s-a oprit din a mai efectua vreo operație.
- Bizantine: atunci când serverul nu respectă întotdeauna protocoalele iniţiale iar componentele salvate local au fost compromise.
- Scurgeri de informații: serverul execută protocoalele corect dar e posibil ca un adversar să fi obținut componentele stocate.

Primele 2 modele definite mai sus sunt preluate din calculul cu sisteme distribuite. Cel de-al 3-lea model a fost introdus pentru a defini atacatorul care foloseste vulnerabilitățile cu intenția de a *învața* din informații.

Arhitectura GridSharing constă in N servere unde cel mult c servere pot fi abandonate, b servere bizantine și l cu scurgeri de informații. Cele N pot fi aranjate într-un grid cu r linii și N/r coloane (considerăm pentru simplitate că $N \pmod{r} = 0$). Caracteristicile modelului bizantin și cel specific scurgerilor de informații permit dezvăluirea componentelor unui adversar de pe cel mult l+b servere.

Exemplul 2. Notăm $\binom{x}{y}$ fiind combinări de x elemente grupate câte y. Considerăm ca împarțim un secret S la 4 linii (participanți) astfel încât sistemul să permită 2 componente de tip b, 1 componentă de tip l și 20 servere. În cazul acesta vom folosi o schemă majoritară XOR $\binom{4}{3}, \binom{4}{3} = (4, 4)$.

Vom avea 4 componente, (s_1, s_2, s_3, s_4) a.î. $s_1 \oplus s_2 \oplus s_3 \oplus s_4 = \mathcal{S}$. Distribuirea se face in felul următor:

- Serverele situate pe prima linie primesc s_1
- Serverele situate pe a 2-a linie primesc s_2
- Serverele situate pe a 3-a linie primesc s_3
- Serverele situate pe a 4-a linie primesc s_4

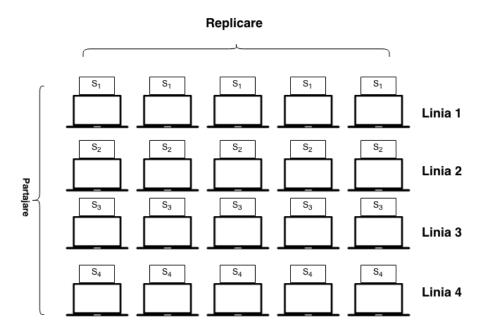


Fig. 7: GridSharing cu 4 linii, 20 servere dintre care 2 bizantine, 1 cu scurgeri de informații [17].

4.3 POTSHARDS

În 2007 este propus un nou sistem care combină caracteristicile PASIS şi Grid-Sharing adăugând posiblitatea de migrarea a datelor la noduri noi: Protection Over Time, Securely Harboring And Reliably Distributing Stuff (POT-SHARDS) [14].

POTSHARDS poate fi gândit ca o aplicație pe partea clientului care comunică cu o mulțime de noduri (arhive) independente, folosind reconstrucția componentelor într-un mod securizat și semnături algebrice pentru a asigura un grad ridicat de păstrare a integritații fișierelor [21].

Confidențialitatea este asigurată prin adoptarea unei scheme de partajare XOR unanimă, la fel ca în GridSharing.

Ca prim pas, POTSHARDS preprocesează fișierul într-un obiect, partajează obiectul în fragmente la care adaugă meta-date, numite *shards* (Fig. 8) [14]. Acestea sunt trimise apoi arhivelor independente, fiecare având propriul domeniu de securitate, localizate in *regiuni*. Pentru a reconstitui cu succes informația inițială, meta-datele shard-urilor conțin detalii despre structura pointerilor aproximativi,

indicând regiunea în care se află următorul shard. Pointerii aproximativi sunt folositi pentru a reconstitui intreaga arhiva doar din shard-uri.

Obiect										
160	160 128									
Hash	ID	Date								
	Fragment									
160	128	128	8	128*Nr						
Hash	ID Obiect	ID Nr Lista SplitXOR(Obi-								
	Shard									
128										
Hash	ID	SplitShamir(Fragment)								

Fig. 8: Entități de date in POTSHARDS. Nr e numărul de shard-uri produse de un fragment. SplitXOR reprezintă o componentă rezultată în urma partajarii unanime XOR. Analog SplitShamir reprezintă o componentă rezultată în urma partăjarii folosind schema Shamir. [14]

Procesul de fragmentare a datelor este prezentat in Fig. 9.

Pentru ca reconstituirea unui fișier sa fie fezabilă unui utilizator, acestuia îi este întoarsă o listă cu locațiile exacte shard-urilor corespunzătoare. Obținerea unui shard de către un atacator nu este folositoare, pentru a detecta următorul shard, un atac brut force constă în cereri multiple în zona indicată de pointerul aproximativ. Un astfel de atac nu va trece neobservat de POTSHARDS deorece unul dintre scopurile sale este să stocheze datele într-un mod cat mai uniform distribuit. [14]

5 Sistemul de stocare Alouneh et al.

Alouneh et al. propun un sistem pentru stocarea sigură a datelor un timp indelungat folosind schema Shamir cu câteva modificări. Aceste schimbări se vor arăta esențiale mai târziu în menținerea securității [22].

Pentru stocarea unui fișier în sistem (abordând filozofia majorității sistemelor de operare - orice este un fișier), o aplicație client îl împarte în blocuri de octeți de lungime k. Pentru fiecare bloc, octeții devin coeficienții unui polinom f de grad k, componenta corespunzătoare participantului i va fi reprezentată de valoarea lui f(i), $i = \{1, 2, \ldots, n\}$. Menționăm că toate operațiile se vor efectua in GF(256) modulo un polinom ireductibil (în implementarea sistemului, autorii folosesc $x^8 + x^5 + x^3 + x + 1$). Procedeul este descris in detaliu in Fig 10.

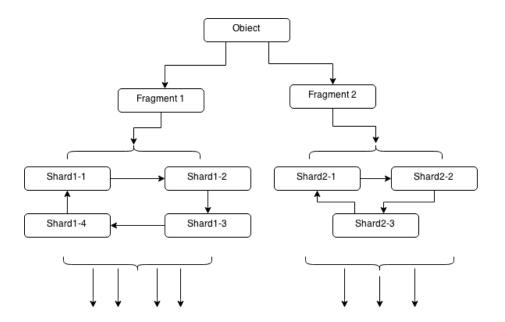


Fig. 9: Distribuirea unui obiect in POTSHARDS

Date de intrare: Un fișier binar S;

Date de ieșire: n fișiere binare distribuite la noduri din rețea;

Procesarea componentelor: Aplicația existentă pe partea clientului:

- Dacă S nu are o lungime divizibilă cu k:
 - Concatenează la sfârsitul lui \mathcal{S} octeți până când $len(\mathcal{S}) \pmod{k} = 0$;
- Împarte S în blocuri de lungime k;
- Repetă pentru fiecare bloc B_t de lungime k:

 Construiește polinomul $f(x) = B_{t_{k-1}}x^{k-1} + B_{t_{k-2}}x^{k-2} + \dots + B_{t_1}x + B_{t_0}$;
 - Calculează f(i) pentru $1 \le i \le n$;

Distribuție: Aplicația la nivelul clientului:

– Distribuie componenta f(i) nodului din rețea cu indicele i:

Fig. 10: Schema Alouneh et al. - Generare [22]

Exemplul 3. Vom exemplifica modul de calcul în $GF(256) \pmod{g(x)}$ unde $g(x) = x^8 + x^4 + x^3 + 1$. Lu
ăm polinomul f(x) = 10 + 15x corespunzâtor unui fișier format din octeții (în această ordine) 10 15.

$$f(01) \pmod{g(x)} = 10 + 15 \pmod{g(x)}$$

$$= (x^4) + (x^4 + x^2 + 1) \pmod{g(x)}$$

$$= x^2 + 1 = 000000101_{(2)}$$

$$= 05_{(16)}$$
(3)

$$f(02) \pmod{g(x)} = 10 + 15 \cdot 02 \pmod{g(x)}$$

$$= (x^4) + (x^5 + x^3 + x) \pmod{g(x)}$$

$$= 00111010_{(2)}$$

$$= 3A_{(16)}$$
(4)

Reconstituirea unui fișier (Fig. 11) se realizează din orice mulțime de componente A de dimensiune minim k folosind interpolarea Lagrange (utilizată și în cadrul schemei Shamir):

$$f(x) = \sum_{i \in A} f(i) \prod_{j \in A, j \neq i} \frac{x - j}{i - j}$$

$$\tag{5}$$

Exemplul 4. Vom exemplifica interpolarea conform ecuației 5 folosind componentele (3) și (4) calculate în exemplul anterior:

$$f(x) = 05(x - 02)(01 - 02)^{-1} + 3A(x - 01)(02 - 01)^{-1}$$

$$= 05(x - 02)03^{-1} + 3A(x - 01)03^{-1}$$

$$= F6(05 + 3A)x + F6(05 \cdot 02 + 3A \cdot 01)$$

$$= F6 \cdot 3F \cdot x + F6 \cdot 30 = 15x + 10$$
(6)

Noutatea arhitecturii constă în diminuarea redundanței componentelor la un factor de k, spre deosebire de sistemele descrise în Secțiunile 4.1, 4.2 și 4.3. Reducerea spațiului ocupat de componente este datorat înlocuirii coeficienților generați aleator din schema Shamir cu octeții din fișierul ce va fi partajat, fiecare componentă având nevoie de 1/k din dimensiunea fișierului \mathcal{S} .

Abordarea acestei metode deterministe conduce la insecuritatea sistemului, Alouneh et al. afirmând în mod eronat că securitatea este indusă în mod automat de schema Shamir.

6 Rezultate obţinute

Împreună cu mentorul am analizat sistemul Alouneh et al. prezentat în Secțiunea 5 [22]. Am indentificat erori majore ale acestuia și am implementat sistemul descris de autori pentru a demonstra practic, nu doar teoretic anumite greșeli pe care le vom evidenția în următoarele secțiuni.

Date de intrare: Cel puțin k componente provenite din noduri (distincte);

Date de ieşire: Fişierul binar original S;

Reconstrucție: Aplicația existenta pe partea clientului:

- Repetă pentru fiecare bloc al lui S:
 - Calculează prin interpolare coeficienții lui $f(x) = B_{t_{k-1}}x^{k-1} + B_{t_{k-2}}x^{k-2} + \dots + B_{t_1} + B_{t_0}$
 - Reconstituie blocul B_t
- Șterge octeții de la sfârșitul fișierului adăugați la generare.

Fig. 11: Schema Alouneh et al. - Reconstrucție [22]

6.1 Vulnerabilități evidențiate

Spre deosebire de schema Shamir, unde coeficienții (cu excepția termenului liber, care este egal cu secretul) sunt aleși într-un mod aleator uniform, sistemul propus de Alouneh et al. folosește o schemă modificată Shamir în care coeficienții sunt extrași din conținutul fișierelor originale. Alegerea este motivată de faptul ca mulțimea componentelor și efortul computațional depus pentru generarea coeficienților se reduce la un factor de k ori, spre deosebire de schema Shamir.

Datorită determinismului, partajarea unui fișier de mai multe ori implică obținerea de componente identice. Determinismul duce la câteva atacuri simple în momentul în care un atacator obține informațiile stocate într-un nod, indiferent de mărimea pragului folosit în metoda de partajare. În acest sens, am evidențiat 2 atacuri simple în cazul în care componentele sunt calculate in ordine $(f(01), f(02), \ldots)$:

- Detectarea tipului unui fişier
- Detectarea conținutului unui fișier

Deoarece Alouneh et al. nu menționeaă o metoda de padding, am indicat că un atac bazat pe felul în care se realizează completarea fișierului (padding) \mathcal{S} înainte de partajarea sa poate fi fezabil, în condițiile în care s-a demonstrat ca această alegere este esențială în păstrarea securității [23].

6.1.1 Detectarea tipului de fișier

În tehnologia informației, la inceputul fiecărui fișier se află o secvență de octeți (denumită semnatură sau antet) cu rolul de a identifica tipul acestuia. Tabelul 1 indică 7 din cele mai uzuale antete.

Se consideră cazul în care partajarea unui fișier pdf se face cu ajutorul sistemului descris in Secțiunea 5, folosind $k \leq 4$. Polinomul corespunzător f(x) va fi intotdeauna același. Presupunând ca numerotarea nodului i este aceeași, putem determina cu ușurință dacă este stocat un fișier pdf fără a lua în calcul conținutul fișierului. Acest atac este fezabil deorece valoarea lui k este publică iar i poate sa fie descoperit în momentul distribuirii.

Cu alte cuvinte, dacă un adversar obtine controlul unui singur nod, bazându-se doar pe valoarea primei componente poate detecta tipul unui fișier.

Pentru a exemplifica, un adversar poate distinge cu probabilitate ridicată între fișierele doc, gif, pdf, png, rar, wav și zip. În Tabelul 2 avem generate componentele pentru k=2 și n=5. Dacă un adversar descoperă valoarea primului nod iar prima componentă este 14 atunci acesta știe cu certitunde că aceasta corespunde un fișier gif. Dacă obține accesul nodului 4 și citește valoarea 205 atunci știe că fișierul este de tipul rar. Daca citește valoarea 27 de pe primul nod atunci știe că poate fi un wav sau zip; dar poate să distingă cele 2 fișiere cu probabilitate 1 dacă dezvăluie o singură valoare de pe celelalte noduri (2, 3, 4 sau 5) pentru că valorile sunt distincte.

Tabel 1: Semnături de fișiere

Tip de fişier	Pri	mii	4 oc	cteţi
doc	D0	CF	11	E0
gif	47	49	46	38
pdf	25	50	44	46
png	89	50	4E	47
rar	52	61	72	21
wav	52	49	46	46
zip	50	4B	03	04

Tabel 2: Componentele primului bloc (k = 2)

Tip fisier	Nod 1	Nod 2	Nod 3	Nod 4	Nod 5
	(i=1)	(i=2)	(i=3)	(i=4)	(i = 5)
doc	31	85	154	193	14
gif	14	213	156	120	49
pdf	117	133	213	126	46
png	217	41	121	210	130
rar	51	144	241	205	172
wav	27	192	137	109	36
zip	27	198	141	103	44

6.1.2 Detectarea de conţinut

Multe documente urmează un anumit tipar precum contracte, chitanțe, bonuri fiscale sau curriculum vitae. Deoarece majoritatea conținutului rămâne neschimbat, există o probabilitate destul de mare ca multe componente sa aiba aceeași valoare. O dată ce un adversar reușește să determine componentele unui nod, poate determina prin analogie tipul de conținut al fișierului original.

Fișierele vulnerabile sunt cele care conțin o secvență de octeți periodică (imagini cu un pattern repetitiv) sau cele care au preponderent octeți nuli (valoarea componentelor asociată majorității blocurilor fiind 0). Spre deosebire de prima metodă, aceasta nu necesită compararea cu un al 2-lea fișier, tratând componentele de sine stătător. Multiple componente identice indică existența unor secvențe repetitive în conținutul fișierului.

6.2 Implementare şi rezultate practice

Pentru a arăta aplicabilitatea rezultatelor în practică, am implementat propunerea descrisa in Secțiunea 5 și am testat pe câteva cazuri.

În cadrul implementării am folosit limbajul Python 3.0 sub sistemul de operare ArchLinux. Python este un limbaj high-level, permiţând programatorilor să exprime concepte în mai puţine linii de cod faţă de C++ sau Java şi este disponibil sub licenţă open-source [24]. Pentru a realiza comunicarea între procese am folosit Cerealizer iar distribuţia componentelor a fost generată grafic cu ajutorul pachetului Matplotlib [25,26]. De asemenea am folosit sistemul de versionare Git iar în prezent codul folosit este găzduit de GitHub [27,28].

Având în vedere că articolul original nu menționează o metodă de padding, am considerat o metodă standard pentru a completa octeții ultimului bloc: alipim la sfârșitul lui $\mathcal S$ octeții 80 00 ... 00 00 până când lungimea ultimului bloc ajunge la k octeți.

Menţionăm această metoda doar pentru completitudine, aceasta neafectând rezultatele, care consideră doar secvenţele de octeţi din antet sau de la începutul fişierului.

6.2.1 Detectarea tipului de fișier

Extindem analiza făcută în Secțiunea 6.1.1 asupra tipurilor de fișiere din Tabelul 1 pentru k=2 și creștem valoarea indicelui i până când 2 componente devin egale. Fie f_l polinomul de gradul 1 asociat primului bloc al fișierului aflat pe linia l. Analog f_c polinomul de gradul 1 asociat primului bloc al fișierului aflat pe coloana c.

Tabelul 3 prezintă valoarea maximă a nodul i pentru care $f_l(i) \neq f_c(i)$. Valoarea -1 indică lipsă de coliziuni ale lui $f_c(x)$, $f_l(x)$ pentru i, i = 1, 2, ..., 255 ($\not\exists 1 \leq i \leq 255$ a.î. $f_l(i) = f_c(i)$)).

Deoarece pe diagonala principală toate componentele sunt identice pentru $k \leq 4$, poate fi ignorată. În Tabelul 3 observăm valoarea 0 pentru perechea (wav, zip) pentru că $f_{wav}(1) = f_{zip}(1) = 27$ (Tabelul 1).

Tabelele 4 și 5 prezintă rezultatele pentru k=3 si k=4. Pentru $k\geq 5$ este nevoie de un antet cu mai mult de 4 octeți.

Considerăm metoda de distribuire descrisă exact ca în Tabelul 10, și anume nodul de stocare i primește componenta f(i). Dacă un atacator preia controlul nodului cu valoarea i acesta poate face distincția între tipul a 2 fișiere partajate cu probabilitate 1 dacă i e mai mic decât valoarea afișată în tabel.

Spre exemplu, un adversar care obține accesul unui singur nod de stocare, iar partajarea a fost făcută pentru k=2 poate distinge cu probabilitate 1 între un fișier doc sau pdf dacă $i \leq 194$. Deoarece n>194 nu se întâmplă în practică, acest atac funcționează. Faptul că multe valori sunt ridicate și majoritatea sunt -1 (Tabelul 4), indică un nivel scăzut de securitate al schemei. În cazul celor cu -1 un adversar va caștiga întotdeauna cu probabilitatea 1, indiferent de indicele nodului de stocare pe care il obține.

Precizăm că acest atac funcționează doar dacă nodurile de stocare își păstrează indexul în cazul partajării repetate a.î. aplicația disponibilă pe partea de client calculează cele n valori $f(i_1), \ldots, f(i_2)$ pentru i_1, \ldots, i_n distincte și păstrează nodul j asociat lui i_j .

Tabel 3: Indicele maxim i a.î. componentele primului bloc sa fie distincte(k=2)

Tip Fişier	doc	gif	pdf	png	rar	wav	zip
doc	-	169	194	209	170	206	110
$_{ m gif}$	169	-	133	137	75	-1	133
pdf	194	133	-	-1	115	151	133
png	209	137	-1	-	229	147	195
rar	170	75	115	229	-	-1	42
wav	206	-1	151	147	-1	-	0
zip	110	133	133	195	42	0	-

Tabel 4: Indicele maxim i a.î. componentele primului bloc sa fie distincte(k=3)

Tip Fişier	doc	gif	pdf	png	rar	wav	zip
doc	-	63	-1	-1	-1	-1	-1
gif	63	-	-1	-1	-1	-1	-1
pdf	-1	-1	-	164	-1	119	-1
png	-1	-1	164	-	143	122	129
rar	-1	-1	-1	143	-	143	-1
wav	-1	-1	119	122	143	-	172
zip	-1	-1	-1	129	-1	172	-

Tabel 5: Indicele maxim i a.î. componentele primului bloc sa fie distincte(k=4)

Tip Fişier	doc	gif	pdf	png	rar	wav	zip
doc	-	-1	38	95	1	95	98
gif	-1	-	-1	-1	167	-1	-1
pdf	38	-1	-	12	11	119	70
png	95	-1	12	-	243	95	148
rar	1	167	11	243	-	-1	94
wav	95	-1	119	95	-1	-	-1
zip	98	-1	70	148	94	-1	-

6.2.2 Detectarea de conţinut

Considerăm scenariul pentru detectarea conținutului unui fișier, demonstrând practic cum un adversar poate să facă diferența între 2 componente stocate pe același nod aparțin unor documente similare. Atacul presupune accesul la un singur nod, indiferent de mărimea pragului k.

Pentru experiment am ales 3 fisiere pdf disponibile online la [29]:

- Europass Curriculum Vitae BG, Bulgaria;
- Europass Curriculum Vitae DK, Dannemark;
- Europass Mobility RO, Romania.

Primele două fișiere reprezintă șablonul pentru un CV european în limba bulgară, respectiv daneză. Observăm că nu doar conținutul șabloanelor diferă, dar și limba în care au fost traduse. Cel de-al treilea fișier este complet diferit de primele două, fiind un document personal în limba română, folosit pentru înregistrarea cunoștiintelor dobăndite într-o țară europeană.

Pentru a arăta vulnerabilitatea sistemului Alouneh et al. [22], partajăm cele 3 fișiere folosind schema (2, 4). Experimentul reprezintă o implementare practică a metodei prezentate in Fig. 10.

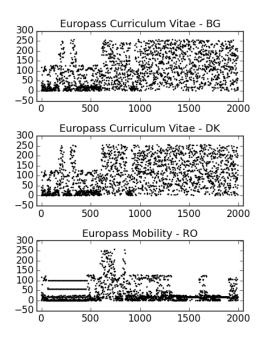


Fig. 12: Nod 1: Graficul componentelor pentru primele 2000 de blocuri

Fig. 12, 13, 14, 15 conțin 2000 de componente generate pentru cele 3 fișiere, stocate în baza de date corespunzătoare nodurilor 1, 2, 3 și 4. Presupunem că indicele i este fixat, polinoamele fiind evaluate în același nod i. Un adversar care obține componentele unui nod poate deduce cu ușurinta graficul lor.

Considerăm că un adversar reuşește să obțină componentele din Fig. 12. Poate deduce uşor că primele două fișiere au un număr mare de componente identice iar cel de-al 3-lea este diferit de primele.

Din cauza șablonului pe care îl respectă cele două CV-uri, un adversar are nevoie în cazul de față doar de primele 500 de componente pentru a constata similiaritatea celor 2 cu o probabilitate ridicată. Diferența vizuala este evidentă între oricare din cele 4 grafice, deci un adversar poate reuși să afle informații despre fișierele partajate indiferent de nodul de stocare vulnerabil.

Considerăm în continuare un alt scenariu, în care partajăm o imagine pentru care informația se repetă. Fie imaginea din Fig. 16 partajată folosind schema

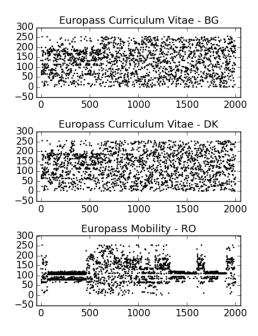


Fig. 13: Nod 2: Graficul componentelor pentru primele 2000 de blocuri

din Secțiunea 5 având 4 noduri iar informația stocată pe cel puțin 2 din ele pot reconstitui imaginea partajată inițial. 10. La fel ca în exemplul precedent, Fig. 17, 18, 19, 20 reprezintă grafic componente imaginii din Fig. 16. Un adversar constată cu uşurință prin obținerea informațiilor stocate aflate pe un singur nod (indiferent de mărimea pragului k) că fișierul original conține un pattern care se repetă.



 ${\bf Fig.\,16:}$ Imagine conținând pattern-uri

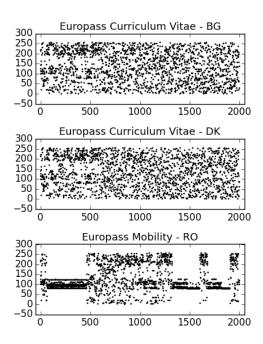


Fig. 14: Nod 3: Graficul componentelor pentru primele 2000 de blocuri

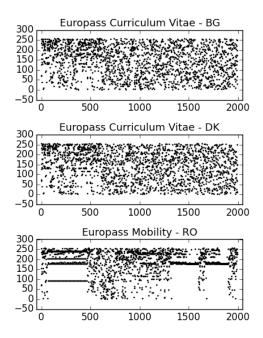


Fig. 15: Nod 4: Graficul componentelor pentru primele 2000 de blocuri

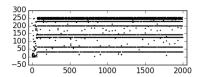


Fig. 17: Nod 1: Graficul componentelor pentru primele 2000 de blocuri

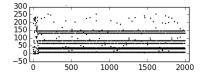


Fig. 18: Nod 2: Graficul componentelor pentru primele 2000 de blocuri

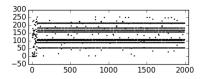


Fig. 19: Nod 3: Graficul componentelor pentru primele 2000 de blocuri

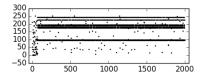


Fig. 20: Nod 4: Graficul componentelor pentru primele 2000 de blocuri

6.3 Publicarea rezultatelor

Pe baza rezultatelor obținute am redactat (împreună cu mentorul) un articol, aflat momentan în procesul de recenzie la Journal of Control Engineering and Applied Informatics (jurnal indexat ISI,categoria C). [30]

Referințe

- WebSite: The Caesar cipher (2015) Ultima accesare: Februarie, 2015, http://www.cs.trincoll.edu/crypto/historical/caesar.html.
- WebSite: Hacking the Vigenere cipher (2015) Ultima accesare: Februarie, 2015, http://inventwithpython.com/hacking/chapter21.html.
- 3. Katz, J., Lindell, Y.: Introduction to Modern Cryptography (Chapman & Hall/Crc Cryptography and Network Security Series). Chapman & Hall/CRC (2007)
- Beimel, A.: Secret-sharing schemes: a survey. In: Coding and cryptology. Springer (2011) 11–46
- Hillery, M., Bužek, V., Berthiaume, A.: Quantum secret sharing. Physical Review A 59(3) (1999) 1829
- Csirmaz, L.: The size of a share must be large. Journal of cryptology 10.4 (1997) 223–231
- Martin, K.M.: Challenging the adversary model in secret sharing schemes. Coding and Cryptography II, Proceedings of the Royal Flemish Academy of Belgium for Science and the Arts (2008) 45–63
- 8. Boneh, D.: The decision Diffie-Hellman problem. In: Algorithmic number theory. Springer (1998) 48--63
- Blakley, G.: Safeguarding cryptographic keys. Proceedings of the 1979 AFIPS National Computer Conference (1979) 313–317
- 10. Shamir, A.: How to share a secret. Commun. ACM 22(11) (1979) 612-613
- 11. Ito, M., Saito, A., Nishizeki, T.: Secret sharing scheme realizing general access structure. Electronics and Communications in Japan (Part III: Fundamental Electronic Science) **72**(9) (1989) 56–64
- Benaloh, J., Leichter, J.: Generalized secret sharing and monotone functions.
 In: Proceedings on Advances in Cryptology. CRYPTO '88, New York, NY, USA, Springer-Verlag New York, Inc. (1990) 27–35
- 13. Karnin, E.D., Member, S., Greene, J.W., Member, S., Hellman, M.E.: On secret sharing systems. IEEE Transactions on Information Theory **29** (1983) 35–41
- 14. Storer, M.W., Greenan, K.M., Miller, E.L., Voruganti, K.: Potshards a secure, recoverable, long-term archival storage system. TOS 5(2) (2009)
- Shor, P.W.: Algorithms for quantum computation: discrete logarithms and factoring. In: Foundations of Computer Science, 1994 Proceedings., 35th Annual Symposium on, IEEE (1994) 124–134
- 16. Wylie, J.J., Bigrigg, M.W., Strunk, J.D., Ganger, G.R., Kiliççöte, H., Khosla, P.K.: Survivable information storage systems. Computer **33**(8) (2000) 61–68
- 17. Subbiah, A., Blough, D.M.: An approach for fault tolerant and secure data storage in collaborative work environments. In: StorageSS. (2005) 84–93
- 18. Patterson, D.A., Gibson, G., Katz, R.H.: A case for redundant arrays of inexpensive disks (raid). SIGMOD Rec. 17(3) (June 1988) 109–116
- Chen, P.M., Lee, E.K., Gibson, G.A., Katz, R.H., Patterson, D.A.: Raid: High-performance, reliable secondary storage. ACM Comput. Surv. 26(2) (June 1994) 145–185
- 20. Feldman, P.: A practical scheme for non-interactive verifiable secret sharing. In: Proceedings of the 28th Annual Symposium on Foundations of Computer Science. SFCS '87, Washington, DC, USA, IEEE Computer Society (1987) 427–438
- Schwarz, T.J.E., Miller, E.L.: Store, forget, and check: Using algebraic signatures to check remotely administered storage. In: 26th IEEE International Conference on Distributed Computing Systems (ICDCS 2006), 4-7 July 2006, Lisboa, Portugal. (2006) 12

- 22. Alouneh, S., Abed, S., Mohd, B.J., Kharbutli, M.: An efficient backup technique for database systems based on threshold sharing. JCP 8(11) (2013) 2980–2989
- 23. Vaudenay, S.: Security flaws induced by cbc padding applications to ssl, ipsec, wtls. In: Proceedings of the International Conference on the Theory and Applications of Cryptographic Techniques: Advances in Cryptology. EUROCRYPT '02, London, UK, UK, Springer-Verlag (2002) 534–546
- 24. WebSite: Python Programming Language official website (2015) Ultima accesare: Februarie, 2015, https://www.python.org/.
- Hunter, J.D.: Matplotlib: A 2D graphics environment. Computing In Science & Engineering 9(3) (2007) 90–95
- 26. WebSite: Cerealizer package (2015) Ultima accesare: Februarie, 2015, https://pypi.python.org/pypi/Cerealizer.
- 27. WebSite: Github Official Website (2015) Ultima accesare: Februarie, 2015, https://www.github.com.
- 28. WebSite: Cod Github Official Website (2015) Ultima accesare: Februarie, 2015, https://www.github.com/rdragos/splitting-scheme.
- 29. WebSite: Europass download examples (2014) Ultima accesare: November, 2014, http://www.europass.cedefop.europa.eu/ro/home.
- 30. WebSite: Journal of Control Engineering and Applied Informatics (2015) Ultima accesare: Februarie, 2015, http://www.ceai.srait.ro/index.php/ceai/index.